Bike 데이터 셋을 활용한 데이터 처리 및 시각화

학습 목표

- 파이썬 라이브러리를 활용하는 것을 통해 어떻게 데이터를 분석하는가를 살펴본다.

학습 내용

- 파이썬 라이브러리를 활용하여 우리가 궁금해 하는 것들에 대해 알아보자.
- Bike 데이터 셋에 대하여 데이터 분석을 통해 데이터를 자세히 알아보자.

In [1]:

```
import pandas as pd
```

In [2]:

```
train = pd.read_csv("bike/train.csv", parse_dates=['datetime'])
test = pd.read_csv("bike/test.csv", parse_dates=['datetime'])
```

In [3]:

```
train.columns
```

Out[3]:

```
Index(['datetime', 'season', 'holiday', 'workingday', 'weather', 'temp',
       'atemp', 'humidity', 'windspeed', 'casual', 'registered', 'count'],
      dtype='object')
```

In [4]:

```
test.columns
```

Out[4]:

```
Index(['datetime', 'season', 'holiday', 'workingday', 'weather', 'temp',
       'atemp', 'humidity', 'windspeed'],
      dtype='object')
```

In [5]:

```
train.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 10886 entries, 0 to 10885
Data columns (total 12 columns):
 #   Column      Non-Null Count  Dtype         
---  ------      --------------  -----         
 0   datetime    10886 non-null  datetime64[ns]
 1   season      10886 non-null  int64         
 2   holiday     10886 non-null  int64         
 3   workingday  10886 non-null  int64         
 4   weather     10886 non-null  int64         
 5   temp        10886 non-null  float64       
 6   atemp       10886 non-null  float64       
 7   humidity    10886 non-null  int64         
 8   windspeed   10886 non-null  float64       
 9   casual      10886 non-null  int64         
 10  registered  10886 non-null  int64         
 11  count       10886 non-null  int64         
dtypes: datetime64[ns](1), float64(3), int64(8)
memory usage: 1020.7 KB
```

In [6]:

```
test.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 6493 entries, 0 to 6492
Data columns (total 9 columns):
 #   Column      Non-Null Count  Dtype         
---  ------      --------------  -----         
 0   datetime    6493 non-null   datetime64[ns]
 1   season      6493 non-null   int64         
 2   holiday     6493 non-null   int64         
 3   workingday  6493 non-null   int64         
 4   weather     6493 non-null   int64         
 5   temp        6493 non-null   float64       
 6   atemp       6493 non-null   float64       
 7   humidity    6493 non-null   int64         
 8   windspeed   6493 non-null   float64       
dtypes: datetime64[ns](1), float64(3), int64(5)
memory usage: 456.7 KB
```

(실습1) 데이터를 알아가기 위한 여러가지 질문을 작성해 보자.

01. 이 데이터의 시간(datetime)은 언제부터 언제까지의 데이터일까?

02. 시간대별 빌린대수(count)와 온도(temp)는 과연 상관관계가 있을까?

- 산점도(scatter plot)로 확인해 보기 - matplotlib 활용해 보기
- type은 점으로 표시
- 투명도를 0.2로 표현

03. corr()를 활용하여 count와 다른 feature(특징)간의 상관계수를 확인해 보자.

- 가장 높은 상관관계를 갖는 순서로 정렬시켜보자.(pandas)
- 이를 수평 막대 그래프로 표시해 보자 - matplotlib 활용해 보기

04. 계절별 데이터를 가진다고 하는데, 계절별로 나눠서, 데이터를 확인 및 시각화 해 보자.

- season의 값의 종류와 count를 확인해 보기
- barplot 표시할 때, x축을 1,2,3,4만 표시되도록 하자.

05. 쉬는날과 아닌날의 데이터는 얼마나 될까? 이를 시각화하기

- holiday의 값의 종류와 count를 확인해 보기
- 시각화 해보기(matplotlib 활용)

06. 날씨는 어떤 값을 가지고, 각각의 데이터 수는 얼마나 될까?

- 날씨(weather)의 값의 종류와 count를 확인해 보기
- 시각화 해보기(matplotlib 활용)

07. 각각의 값의 분포를 2행, 2열로 표시해 보자.

- temp의 값의 분포는 어떠할까?
- atemp의 값의 분포는 어떠할까?
- humidity의 값의 분포는 어떠할까?
- windspeed의 값의 분포는 어떠할까?
- 전체 그래프에 대한 제목을 달아보자(suptitle, 크기(size)=20))
- 각각의 그래프에 대한 x축 레이블을 넣어보자(크기는 17)
- 시각화 해보기(matplotlib 활용)

08. 2년 동안 날씨는 어떠했을까? 그리고 데이터의 비율은 어떠한가?

- weather별 데이터의 비율은 어느정도 될까?
- 시각화 해보기(matplotlib 활용)
- 이에 대해서 pie 그래프로 나타내 보자.
- label은 한글로 '봄', '여름', '가을', '겨울'로 표시해 보자.

matplotlib을 사용하여 위의 문제를 풀어보자.

In [7]:

```
import matplotlib.pyplot as plt
import matplotlib
```

01. 이 데이터의 시간(datetime)은 언제부터 언제까지의 데이터일까?

In [8]:

```
train.datetime.describe()
```

```
<ipython-input-8-120836598240>:1: FutureWarning: Treating datetime data as categoric
al rather than numeric in `.describe` is deprecated and will be removed in a future
version of pandas. Specify `datetime_is_numeric=True` to silence this warning and ad
opt the future behavior now.
  train.datetime.describe()
```

Out[8]:

```
count                   10886
unique                  10886
top       2011-06-09 04:00:00
freq                        1
first     2011-01-01 00:00:00
last      2012-12-19 23:00:00
Name: datetime, dtype: object
```

02 시간대별 빌린대수(count)와 온도(temp)는 과연 상관관계가 있을까?

- 산점도(scatter plot)로 확인해 보기
- type은 점으로 표시
- 투명도를 0.2로 표현

In [14]:

```
plt.plot(train['count'], train['temp'], 'o', alpha=0.2)
```

Out[14]:

```
[<matplotlib.lines.Line2D at 0x27bcac1db20>]
```

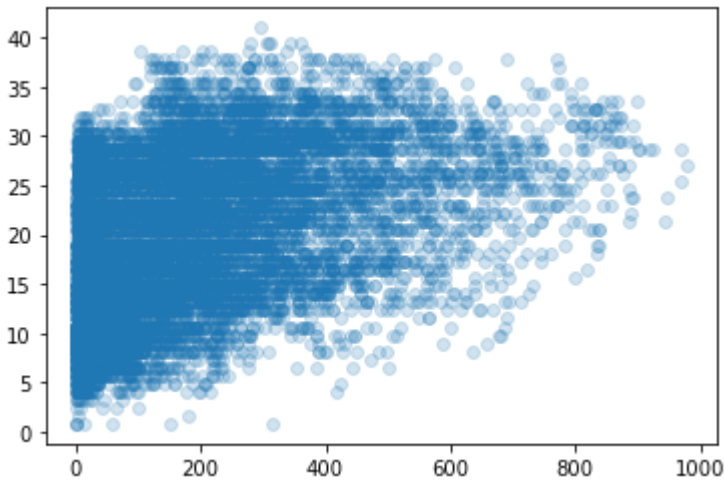

03 corr()를 활용하여 count와 다른 feature(특징)간의 상관계수를 확인해 보자.

- 가장 높은 상관관계를 갖는 순서로 정렬시켜보자.(pandas)
- 이를 수평 막대 그래프로 표시해 보자 - matplotlib 활용해 보기

- x축, y축 레이블, 제목을 표시해보자

In [9]:

```
train.corr()['count']
```

Out[9]:

```
season        0.163439
holiday      -0.005393
workingday    0.011594
weather      -0.128655
temp          0.394454
atemp         0.389784
humidity     -0.317371
windspeed     0.101369
casual        0.690414
registered    0.970948
count         1.000000
Name: count, dtype: float64
```

In [10]:

```
train.corr()['count'].abs().sort_values(ascending=False)
```

Out[10]:

```
count         1.000000
registered    0.970948
casual        0.690414
temp          0.394454
atemp         0.389784
humidity      0.317371
season        0.163439
weather       0.128655
windspeed     0.101369
workingday    0.011594
holiday       0.005393
Name: count, dtype: float64
```

bar plot으로 상관계수를 그래프화 시켜보자.

In [13]:

```
data = train.corr()['count'].abs().sort_values(ascending=True)
print(data.index)
print(data.values)
```

```
Index(['holiday', 'workingday', 'windspeed', 'weather', 'season', 'humidity',
       'atemp', 'temp', 'casual', 'registered', 'count'],
      dtype='object')
[0.00539298 0.01159387 0.10136947 0.1286552  0.16343902 0.31737148
 0.38978444 0.39445364 0.69041357 0.97094811 1.         ]
```

In [14]:

```
plt.barh(data.index, data.values)
```

Out[14]:

```
<BarContainer object of 11 artists>
```

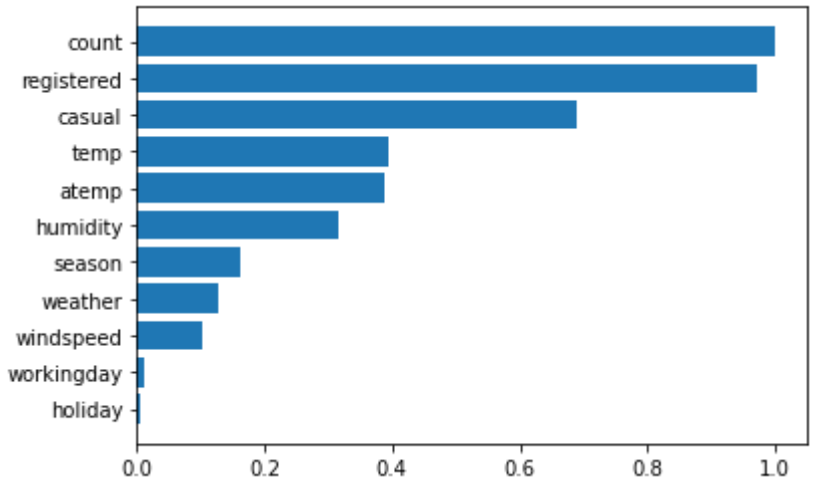

In [15]:

```
plt.barh(data.index, data.values)
plt.title("count corr values")
plt.xlabel("corr values")
plt.ylabel("features")
```

Out[15]:

```
Text(0, 0.5, 'features')
```

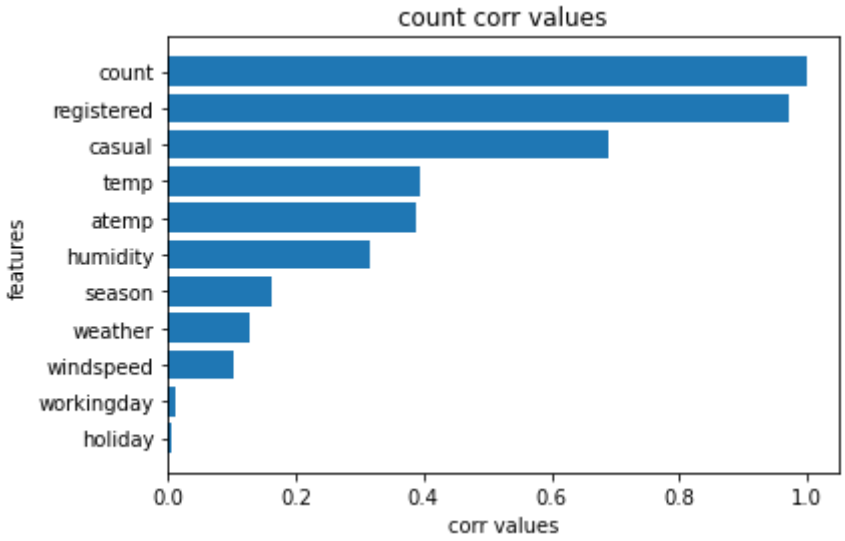

04. 계절별 데이터를 가진다고 하는데, 계절별로 나눠서, 데이터를 확인 및 시각화 해 보자.

- x축을 1,2,3,4만 표시되도록 하자.

In [16]:

```
train['season'].value_counts()
```

Out[16]:

```
4    2734
3    2733
2    2733
1    2686
Name: season, dtype: int64
```

In [17]:

```
data = train['season'].value_counts()
plt.bar(data.index, data.values)
```

Out[17]:

```
<BarContainer object of 4 artists>
```

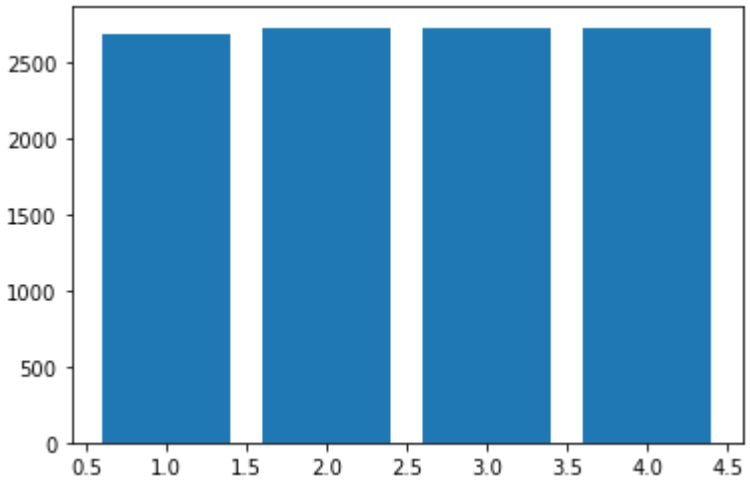

In [18]:

```
plt.bar(data.index.astype(str), data.values)
```

Out[18]:

```
<BarContainer object of 4 artists>
```

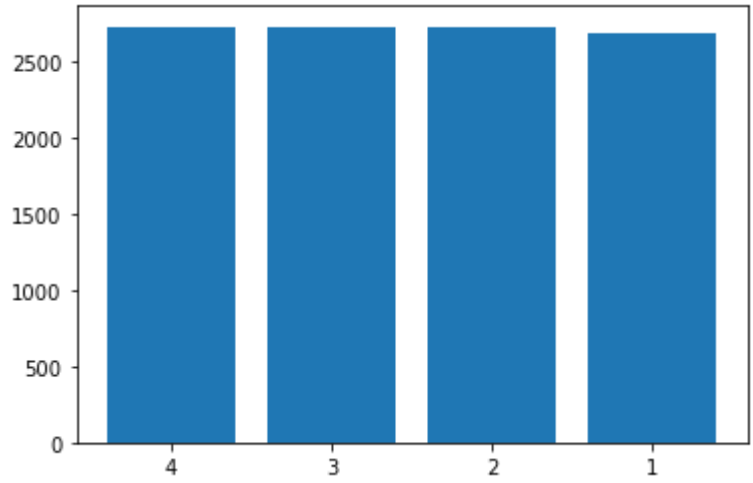

05. 쉬는날과 아닌날의 데이터는 얼마나 될까? 이를 시각화하기

In [19]:

```
train['holiday'].value_counts()
```

Out[19]:

```
0    10575
1      311
Name: holiday, dtype: int64
```

In [20]:

```
data = train['holiday'].value_counts()
plt.bar(data.index.astype(str), data.values)
```

Out[20]:

```
<BarContainer object of 2 artists>
```

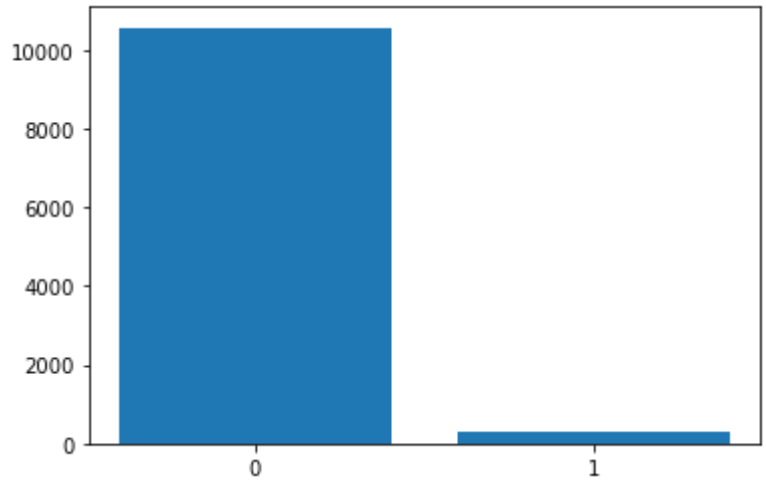

06. 날씨는 어떤 값을 가지고, 각각의 데이터 수는 얼마나 될까?

In [21]:

```
train['weather'].value_counts()
```

Out[21]:

```
1    7192
2    2834
3     859
4       1
Name: weather, dtype: int64
```

In [22]:

```
data = train['weather'].value_counts()
plt.bar(data.index.astype(str), data.values)
```

Out[22]:

```
<BarContainer object of 4 artists>
```

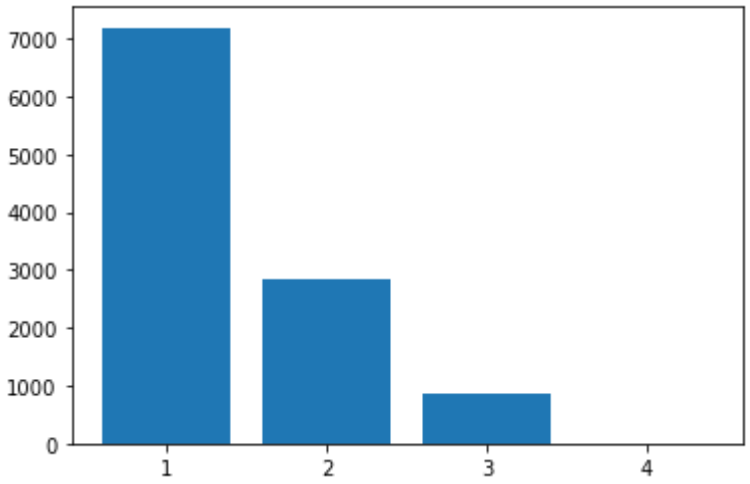

07. 각각의 값의 분포를 2행, 2열로 표시해 보자.

- temp의 값의 분포는 어떠할까?
- atemp의 값의 분포는 어떠할까?
- humidity의 값의 분포는 어떠할까?
- windspeed의 값의 분포는 어떠할까?
- 전체 그래프에 대한 제목을 달아보자(suptitle, 크기(size)=20))
- 각각의 그래프에 대한 x축 레이블을 넣어보자(크기는 17)

In [23]:

```
plt.figure(figsize=(15,10))
plt.subplot(2,2,1)
plt.hist(train.temp)

plt.subplot(2,2,2)
plt.hist(train.atemp)

plt.subplot(2,2,3)
plt.hist(train.humidity)

plt.subplot(2,2,4)
plt.hist(train.windspeed)
```

Out[23]:

```
(array([1.313e+03, 4.083e+03, 2.827e+03, 1.540e+03, 6.960e+02, 2.800e+02,
        1.070e+02, 3.100e+01, 6.000e+00, 3.000e+00]),
 array([ 0.     ,  5.69969, 11.39938, 17.09907, 22.79876, 28.49845,
        34.19814, 39.89783, 45.59752, 51.29721, 56.9969 ]),
 <BarContainer object of 10 artists>)
```

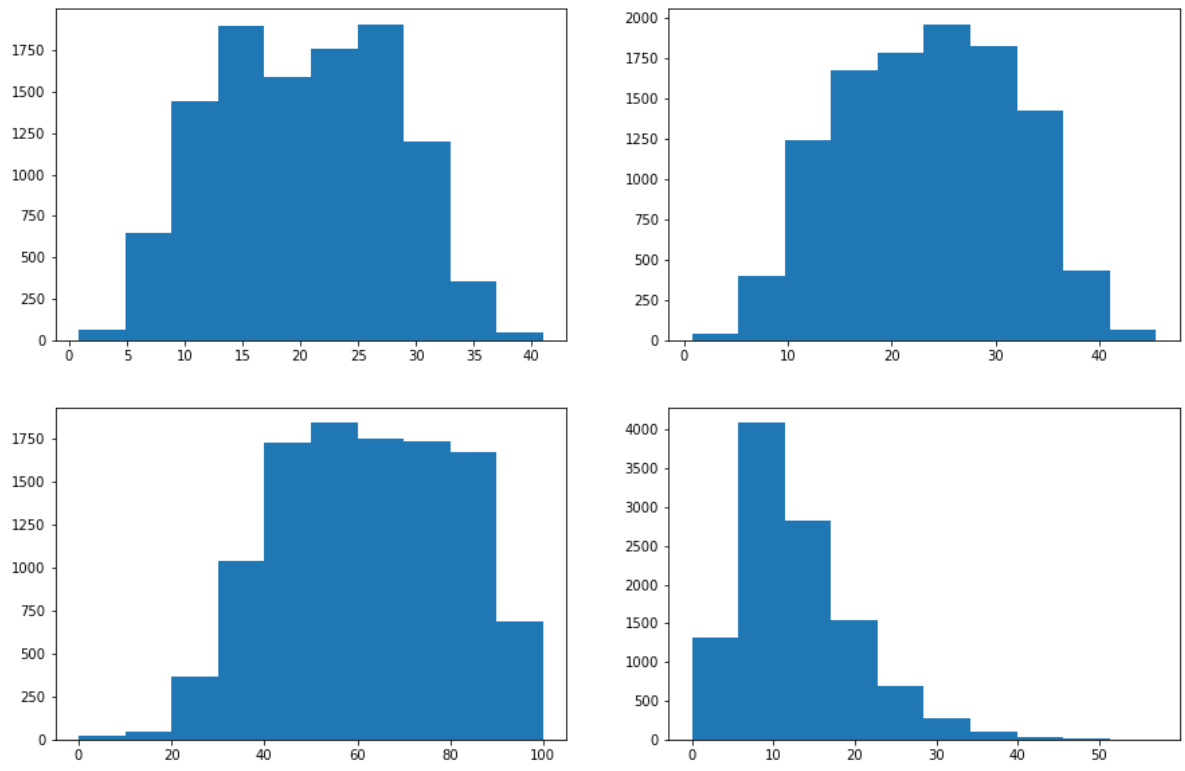

In [24]:

```
plt.figure(figsize=(15,10))
plt.hist(train.temp, alpha=0.3)
plt.hist(train.atemp, alpha=0.3)
plt.hist(train.humidity, alpha=0.3)
plt.hist(train.windspeed, alpha=0.3)
```

Out[24]:

```
(array([1.313e+03, 4.083e+03, 2.827e+03, 1.540e+03, 6.960e+02, 2.800e+02,
        1.070e+02, 3.100e+01, 6.000e+00, 3.000e+00]),
 array([ 0.     ,  5.69969, 11.39938, 17.09907, 22.79876, 28.49845,
        34.19814, 39.89783, 45.59752, 51.29721, 56.9969 ]),
 <BarContainer object of 10 artists>)
```

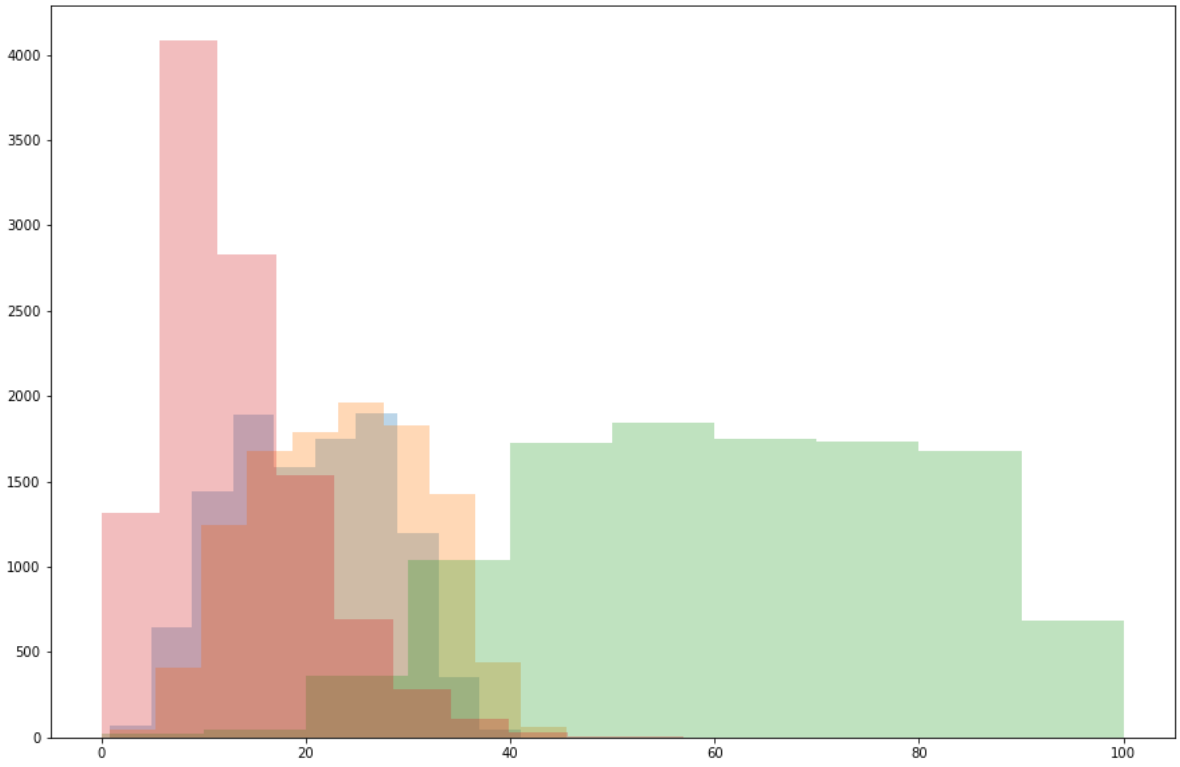

In [25]:

```
from matplotlib import font_manager, rc
import matplotlib.pyplot as plt
import platform
```

In [26]:

```
path = "C:/Windows/Fonts/malgun.ttf"
if platform.system() == "Windows":
    font_name = font_manager.FontProperties(fname=path).get_name()
    rc('font', family=font_name)
elif platform.system()=="Darwin":
    rc('font', family='AppleGothic')
else:
    print("Unknown System")

matplotlib.rcParams['axes.unicode_minus'] = False
```

In [27]:

```
plt.figure(figsize=(15,10))
plt.subplot(2,2,1)
plt.hist(train.temp)
plt.xlabel("temp", size=17)

plt.subplot(2,2,2)
plt.hist(train.atemp, color="#88c999")
plt.xlabel("atemp", size=17)

plt.subplot(2,2,3)
plt.hist(train.humidity, color='#B652BE')
plt.xlabel("humidity", size=17)

plt.subplot(2,2,4)
plt.hist(train.windspeed)
plt.xlabel("windspeed", size=17)

plt.suptitle("피처의 값의 분포", size=20)
```

Out[27]:

Text(0.5, 0.98, '피처의 값의 분포')

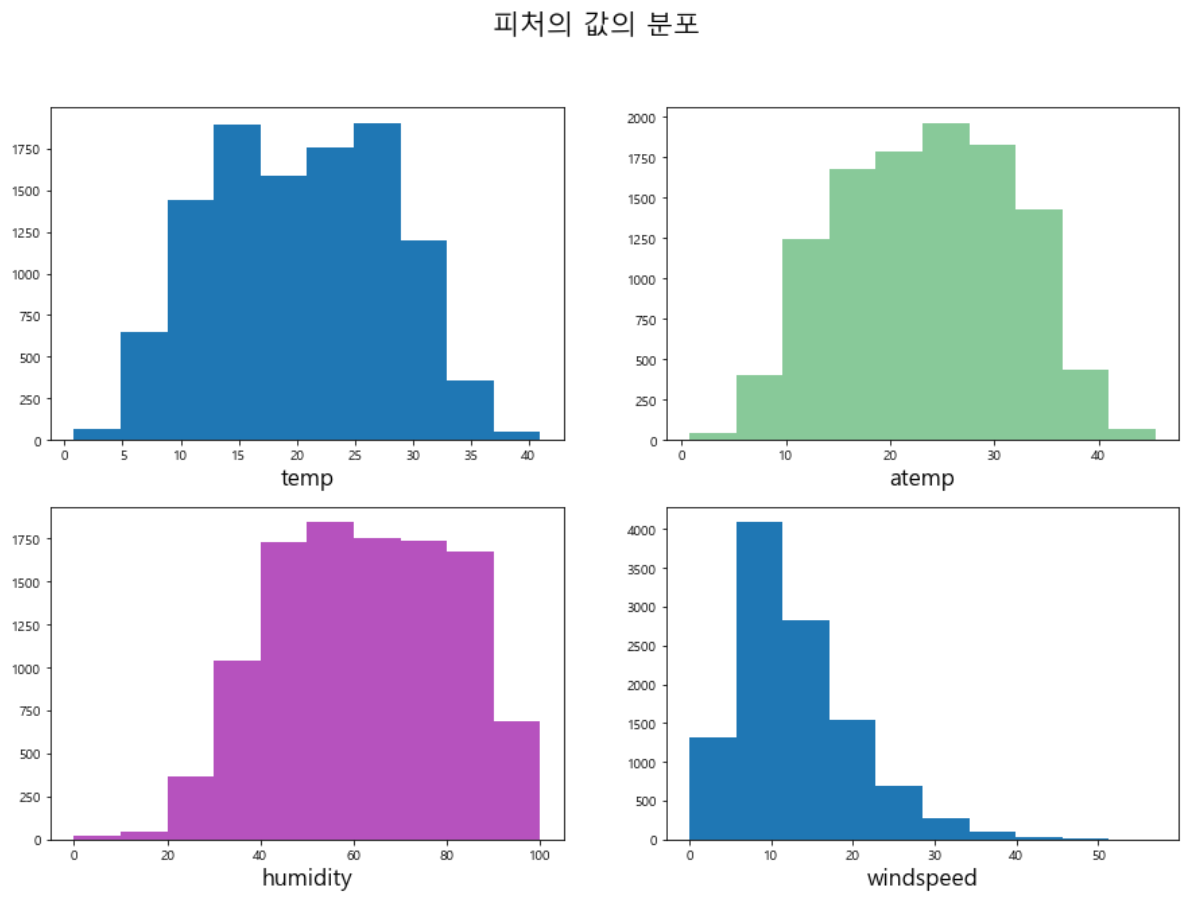

08. 2년 동안 날씨는 어떠했을까? 그리고 데이터의 비율은 어떠한가?

- 이에 대해서 pie 그래프로 나타내 보자.
- label은 한글로 '봄', '여름', '가을', '겨울'로 표시해 보자.

In [28]:

```
print( train['weather'].count() )
all_cnt = train['weather'].count()
print( train['weather'].value_counts() / all_cnt )
```

```
10886
1    0.660665
2    0.260334
3    0.078909
4    0.000092
Name: weather, dtype: float64
```

In [29]:

```
plt.figure(figsize=(10,10))
dat = train['weather'].value_counts() / all_cnt
dat.index=['봄', '여름', '가을', '겨울']
plt.pie(dat.values, labels=dat.index)
plt.legend(title='계절')
```

Out[29]:

```
<matplotlib.legend.Legend at 0x24e9012c4c0>
```